

Exercício 1

Faça o download da tabela de dados [neste link](#). Essa tabela é uma versão simplificada dos dados de campanha de marketing disponível no [Kaggle](#). A partir da tabela fornecida, selecione apenas as variáveis explicativas ('Education', 'Kidhome', 'Teenhome', 'Recency', 'Age', 'Children', 'Family_Size', 'Is_Parent') e faça o que se pede.

a) Utilize um PCA com 2 componentes e responda as seguintes perguntas:

- Qual o percentual total da variância explicada?
- Qual o peso de cada uma das variáveis originais usadas em cada componente, expressos em uma escala de 0 a 100?

b) Utilize um PCA para explicar 99,9% da variância original dos dados:

- Quantos componentes foram selecionados?
- Qual o peso de cada uma das variáveis originais usadas em cada componente, expressos em uma escala de 0 a 100?

c) Utilize a Decomposição em Valores Singulares (SVD) para decompor a matriz de dados padronizada das variáveis explicativas:

- Quais são os valores singulares obtidos e qual sua relação com a variância explicada pelos componentes principais do item (a)?
- Mostre que os vetores singulares à direita correspondem, a menos de sinal, aos componentes principais obtidos no item (a).

d) Utilize o SVD truncado para obter uma aproximação de posto k (rank- k approximation) da matriz de dados:

- Determine o menor posto k para o qual a aproximação preserva pelo menos 99,9% da variância (energia) original dos dados e compare com o número de componentes obtido no item (b).
- Calcule o erro de reconstrução (norma de Frobenius) entre a matriz original e a matriz de posto k obtida via SVD truncado, para $k = 2$ e para o k encontrado no item anterior.

Exercício 2

Faça o download da tabela de dados [neste link](#). Essa tabela fornece um conjunto de 6 indicadores eleitorais para 100 municípios escolhidos aleatoriamente da Paraíba. Os pesquisadores desejam construir um índice de acompanhamento da representatividade a partir desses indicadores. Para tanto, estão estudando quatro possibilidades:

- I_1 : Um índice dado pela média aritmética simples das eficácias dos indicadores;
- I_2 : Um índice dado pela média ponderada das eficácias dos indicadores, onde os pesos são dados pelos elementos apenas do primeiro componente;
- I_3 : Um índice dado pela média ponderada das eficácias dos indicadores, onde os pesos são dados pelos elementos de todos os componentes;
- I_4 : Um índice dado pela média ponderada das eficácias dos indicadores, onde os pesos são dados pelos elementos do primeiro vetor singular à direita obtido via SVD truncado (aproximação de posto $k = 1$) da matriz de indicadores.

Adicione ao Data Frame original com os dados uma coluna para cada índice.

- Quais os três melhores municípios de acordo com cada índice?
- Quais os três piores municípios de acordo com cada índice?
- Crie uma tabela de estatística descritiva conforme modelo abaixo e comente suas principais conclusões sobre os diferentes índices a partir da tabela.

Índice	Média	Desvio-Padrão	Mínimo	Máximo
I1				
I2				
I3				
I4				

d) Utilize o SVD truncado para obter a aproximação de posto $k = 1$ da matriz de indicadores (padronizada). Qual o percentual da variância (energia) total dos dados originais é preservado nessa aproximação de posto k ? Comente a relação entre esse resultado e os pesos utilizados na construção do índice I_4 .

OBS.: A tabela abaixo traz a descrição básica de cada indicador da base do Exercício 2.

Indicador	Conjunto
tse_10_1	Proporção de assentos ocupados pessoas pardas em parlamentos locais
tse_10_4	Proporção de candidatos pardos a parlamentos locais
tse_10_7	Taxa de sucesso de candidatos pardos em eleições locais
tse_5_1	Proporção de assentos ocupados mulheres pardas em parlamentos locais
tse_5_4	Proporção de candidatas pardas a parlamentos locais
tse_5_7	Taxa de sucesso de candidatas pardas em eleições locais

↔ Exercício 3

Uma empresa que possui quatro produtos principais: A, B, C e D. A cada trimestre, uma certa porcentagem de clientes que compraram um produto migra para outro ou permanece fiel ao mesmo produto. Essa dinâmica de mercado pode ser representada por uma matriz de transição abaixo.

	A	B	C	D
A	60%	20%	10%	5%
B	10%	60%	10%	15%
C	20%	10%	50%	40%
D	10%	20%	20%	60%

Encontre a distribuição de clientes no estado estacionário.

Exercício 4

Uma plataforma de streaming deseja construir um sistema de recomendação de filmes a partir das notas (de 1 a 5) dadas por seus usuários. Como nem todo usuário avalia todos os filmes, a matriz de avaliações é esparsa (possui valores faltantes) – situação típica em sistemas de recomendação por filtragem colaborativa (collaborative filtering). A tabela abaixo apresenta essa matriz, em que “–” indica que o usuário não avaliou o filme.

	Filme 1	Filme 2	Filme 3	Filme 4
Ana	5	4	–	1
Bruno	4	–	–	1
Carla	1	1	5	4
Diego	–	1	4	5
Elisa	2	–	5	4

- Trate os valores faltantes da matriz de avaliações (por exemplo, substituindo-os pela média das notas do respectivo usuário, do respectivo filme, ou da matriz como um todo) para viabilizar a aplicação do SVD.
- Aplique o SVD truncado com posto $k = 2$ sobre a matriz preenchida no item (a) e obtenha a matriz de avaliações reconstruída (aproximação de posto k).
- Quais notas o modelo previu para as avaliações originalmente faltantes? Com base nessas notas previstas, para quais pares usuário-filme você recomendaria o filme (considere recomendável uma nota prevista ≥ 4)?
- Repita os itens (b) e (c) utilizando $k = 1$ e $k = 4$ (posto completo). Compare as previsões obtidas nos três casos ($k = 1, 2$ e 4) e discuta o efeito da escolha do posto k sobre a qualidade das recomendações (risco de subajuste com k muito baixo e de sobreajuste ao se aproximar do posto completo).